

# Notițe Seminar 6

November 11, 2019

**Intro:** Până acum am făcut 2 algoritmi de clasificare: ID3, AdaBoost. Mai adăugam acum alți doi algoritmi: **Bayes Naiv** și **Bayes Corelat**.

## Remember 1

Fie funcția  $f : \{1, 2, 3\} \rightarrow \mathbb{R}$  cu  $f(1) = 100, f(2) = 200, f(3) = 300$ . Atunci:

$$\max_{x \in \{1, 2, 3\}} f(x) = 300$$

și

$$\arg \max_{x \in \{1, 2, 3\}} f(x) = 3$$

## Remember 2

Ex.: Estimați în sensul verosimilății maxime (MLE) probabilitățile  $P(A = 0, B = 0)$ ,  $P(A = 0|Y = 1)$ , având următorul tabel cu date:

| A | B | Y |
|---|---|---|
| 0 | 0 | 0 |
| 0 | 1 | 1 |
| 1 | 0 | 1 |
| 1 | 1 | 0 |

Vom nota cu  $\#$ (proprietăți) câte rânduri au anumite proprietăți. De exemplu:  $\#(A = 0)$  = (câte rânduri au  $A = 0$ ).

$$P(A = 0, B = 0) \stackrel{\text{MLE}}{=} \frac{\#(A=0, B=0)}{4} = \frac{1}{4}$$

$$P(A = 0|Y = 1) \stackrel{\text{MLE}}{=} \frac{\#(A=0, Y=1)}{\#(Y=1)} = \frac{1}{2} \text{ (ne uităm doar la rândurile cu } Y = 1)$$

## Înspre clasificare bayesiană

5.

### Classes of Hypotheses

#### Maximum Likelihood (ML) hypothesis:

the hypothesis that best explains the training data

$$h_{ML} = \operatorname{argmax}_{h_i \in H} P(D|h_i)$$

#### Maximum A posteriori Probability (MAP) hypothesis:

the most probable hypothesis given the training data

$$h_{MAP} = \operatorname{argmax}_{h \in H} P(h|D) = \operatorname{argmax}_{h \in H} \frac{P(D|h)P(h)}{P(D)} = \operatorname{argmax}_{h \in H} P(D|h)P(h)$$

**Note:** If  $P(h_i) = P(h_j), \forall i, j$ , then  $h_{MAP} = h_{ML}$

(slide preluat din <https://profs.info.uaic.ro/~ciortuz/SLIDES/ml6.pdf>)  
Aplicare: Vezi ex. 3/pag. 370.

## Clasificare bayesiană

### Bayes Naiv

#### 2.4 The Naive Bayes Classifier

11.

When to use it:

- The target function  $f$  takes value from a finite set  $V = \{v_1, \dots, v_k\}$
- Moderate or large training data set is available
- The attributes  $\langle a_1, \dots, a_n \rangle$  that describe instances are conditionally independent w.r.t. to the given classification:

$$P(a_1, a_2 \dots a_n | v_j) = \prod_i P(a_i | v_j)$$

The most probable value of  $f(x)$  is:

$$\begin{aligned} v_{MAP} &= \operatorname{argmax}_{v_j \in V} P(v_j | a_1, a_2 \dots a_n) = \operatorname{argmax}_{v_j \in V} \frac{P(a_1, a_2 \dots a_n | v_j) P(v_j)}{P(a_1, a_2 \dots a_n)} \\ &= \operatorname{argmax}_{v_j \in V} P(a_1, a_2 \dots a_n | v_j) P(v_j) = \operatorname{argmax}_{v_j \in V} \prod_i P(a_i | v_j) P(v_j) \stackrel{\text{not.}}{=} v_{NB} \end{aligned}$$

This is the so-called *decision rule* of the Naive Bayes classifier.

(slide preluat din <https://profs.info.uaic.ro/~ciortuz/SLIDES/ml6.pdf>)

Atribute de intrare:  $A_1, \dots, A_n$

Atributul de ieșire:  $V$

Antrenare: estimarea/calculul următoarelor probabilități:

$P(v_j), \forall v_j \in \text{Val}(V)$

$P(a_i | v_j), \forall a_i \in \text{Val}(A_i), \forall v_j \in \text{Val}(V)$

Număr de parametri necesari de estimat: vezi ex. indicat mai jos

Testare: utilizați regula de decizie din slide ( $v_{NB}$ ).

Algoritmul este *naiv*, pentru că face presupunerea că atributele de intrare sunt independente condițional față de atributul de ieșire, lucru care nu se întâmplă de cele mai multe ori.

## Bayes Corelat

12.

### The Joint Bayes Classifier

$$\begin{aligned} v_{MAP} &= \operatorname{argmax}_{v_j \in V} P(v_j | a_1, a_2 \dots a_n) = \dots \\ &= \operatorname{argmax}_{v_j \in V} P(a_1, a_2 \dots a_n | v_j) P(v_j) = \operatorname{argmax}_{v_j \in V} P(a_1, a_2 \dots a_n, v_j) \stackrel{not.}{=} v_{JB} \end{aligned}$$

(slide preluat din <https://profs.info.uaic.ro/~ciortuz/SLIDES/ml6.pdf>)

Atribute de intrare:  $A_1, \dots, A_n$

Atributul de ieșire:  $V$

Antrenare: estimarea/calculul următoarelor probabilități:

$P(v_j), \forall v_j \in \text{Val}(V)$

$P(a_1, \dots, a_n | v_j), \forall a_i \in \text{Val}(A_i), \forall v_j \in \text{Val}(V)$

Număr de parametri necesari de estimat: vezi ex. indicat mai jos

Testare: utilizați regula de decizie din slide ( $v_{JB}$ ).

Aplicare + altele (număr de parametri de estimat): vezi ex. 7/pag. 379

## O altă perspectivă asupra algoritmilor Bayes naiv și Bayes corelat

Regula de decizie a ambilor algoritmi poate fi scrisă și astfel:

$$\arg \max_{v_j \in \text{Val}(V)} P_{NB/JB}(a_1, \dots, a_n, v_j)$$

doar că unul calculează probabilitatea folosindu-se de distribuția presupusă de el (mă refer la Bayes naiv care presupune independența condițională a atributelor de intrare față de ieșire), iar altul calculează probabilitatea folosindu-se de distribuția reală.

Altfel spus: având un rând la testare  $(a_1, \dots, a_n)$ , gândiți-vă la rândurile  $(a_1, \dots, a_n, v_1)$ ,  $(a_1, \dots, a_n, v_2)$ , ...,  $(a_1, \dots, a_n, v_k)$ . Calculați probabilitatea fiecărui rând și returnați eticheta corespunzătoare probabilității maxime.

### Netezirea Laplace

În cadrul algoritmului Bayes Naiv, când vreuna din probabilitățile  $P(a_i|v_j)$  este 0, va fi o problemă pentru că produsul care apare în regula de decizie a lui Bayes Naiv va fi 0. Pentru a scăpa de acest neajuns, se folosește regula lui Laplace (netezirea de tip *add-one*):

$$P(A_i = a_i|V = v_j) \stackrel{\text{Laplace}}{=} \frac{\#(A_i = a_i, V = v_j) + 1}{\#(V = v_j) + |\text{Val}(A_i)|}$$

Vă amintesc că fără regula lui Laplace era astfel:

$$P(A_i = a_i|V = v_j) \stackrel{\text{MLE}}{=} \frac{\#(A_i = a_i, V = v_j)}{\#(V = v_j)}$$

Aplicare: vezi ex. 6/pag. 377

Dacă vreți să înțelegeți de unde vine formula, citiți în continuare:

Suntem în contextul ex. 6b/pag. 377 și vrem să calculăm  $P(\text{study} = 1|\text{category} = \text{spam})$ ,  $P(\text{study} = 1|\text{category} = \text{regular})$  cu regula lui Laplace.

Vom construi un tabel cu frecvențe (valoarea din prima celulă va fi egală cu numărul de rânduri cu  $\text{study} = 0$  și  $\text{category} = \text{regular}$ ):

|           | category = regular | category = spam |
|-----------|--------------------|-----------------|
| study = 0 | 1                  | 8               |
| study = 1 | 3                  | 0               |
|           | 4                  | 8               |

Astfel, am putea scrie:

$$P(\text{study} = 1|\text{category} = \text{regular}) \stackrel{\text{MLE}}{=} \frac{3}{4}$$

$$P(\text{study} = 1 | \text{category} = \text{spam}) \stackrel{\text{MLE}}{=} \frac{0}{8}$$

Pentru că avem o celulă cu zero, atunci refacem tabelul adăugând 1 (*add-one...*) la fiecare celulă:

|           | category = regular | category = spam |
|-----------|--------------------|-----------------|
| study = 0 | 2                  | 9               |
| study = 1 | 4                  | 1               |
|           | 6                  | 10              |

Astfel, putem scrie:

$$P(\text{study} = 1 | \text{category} = \text{regular}) \stackrel{\text{Laplace}}{=} \frac{4}{6}$$

$$P(\text{study} = 1 | \text{category} = \text{spam}) \stackrel{\text{Laplace}}{=} \frac{1}{10}$$

## Schemă de final

1. Ipoteze
  - (a) ML
  - (b) MAP
2. Bayes Naiv
  - (a) Antrenare
    - i. algoritm
    - ii. număr de parametri de estimat
  - (b) Testare
3. Bayes Corelat
  - (a) Antrenare
    - i. algoritm
    - ii. număr de parametri de estimat
  - (b) Testare
4. O altă perspectivă asupra alg. BN, JB
5. Netezirea Laplace